4. Групповые взаимодействия и рассылка

Сухорослов Олег Викторович

30.09.2024

План лекции

- Групповые взаимодействия
- Надежная рассылка сообщений в группе
- Масштабируемые подходы к распространению информации

Взаимодействия: число процессов

- Парные взаимодействия
  - point-to-point, one-to-one
  - TCP, RPC, HTTP…
- Групповые взаимодействия (group communication)
  - one-to-many, many-to-many
  - ???

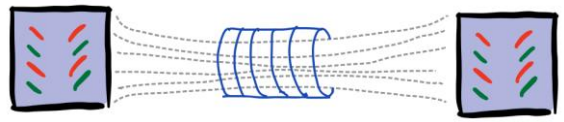

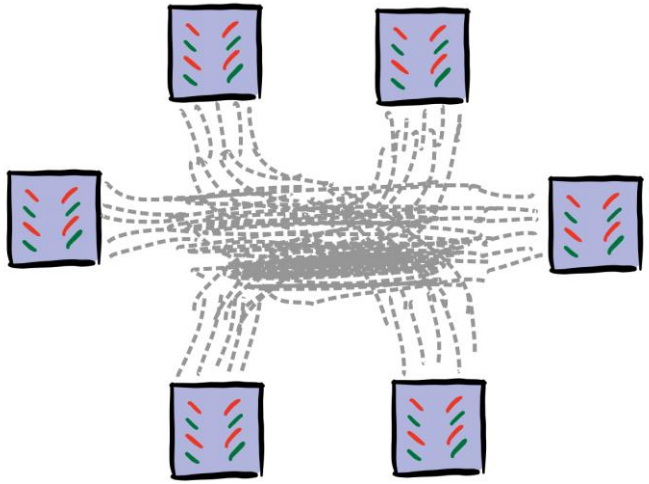

Применение групповых взаимодействий

- Рассылка уведомлений о событиях
- Доставка контента и потоковое вещание
- Поиск сервисов и разрешение имен
- Синхронизация времени
- Поиск данных
- Параллельные вычисления
- Репликация сервисов или данных

Реализация группового взаимодействия

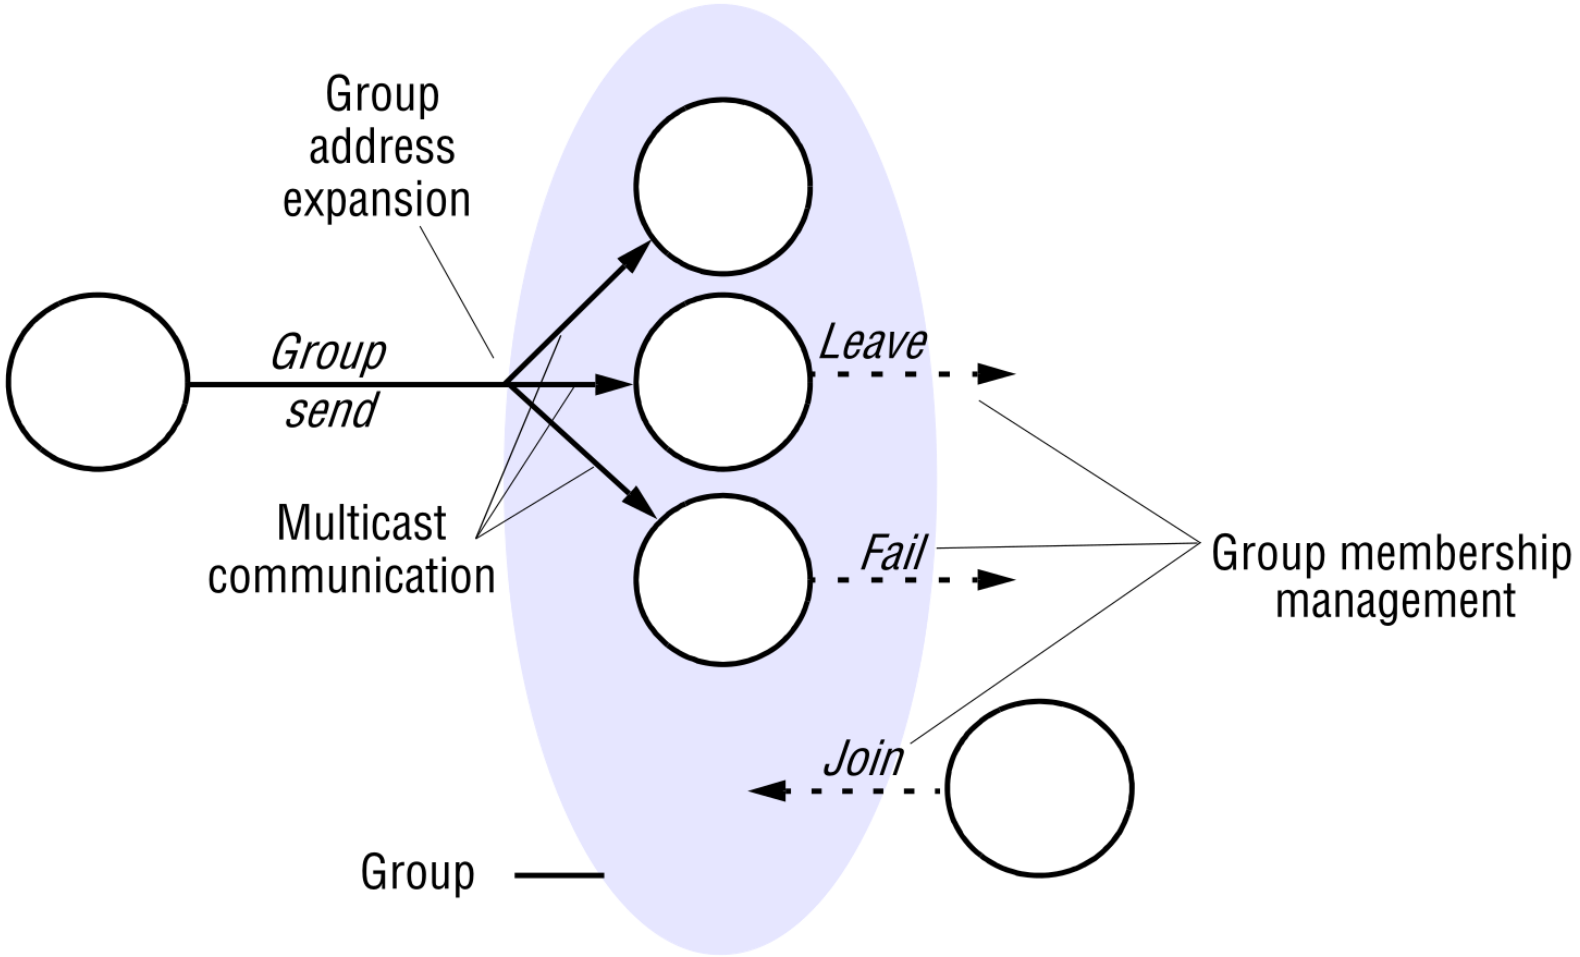

Схемы передачи сообщений

- Unicast (point-to-point)
  - одноадресная передача
- Broadcast
  - широковещательная рассылка
- Multicast
  - многоадресная рассылка
  - source-specific multicast (one-to-many)
  - any-source multicast (many-to-many)
- Anycast
  - передача кому угодно

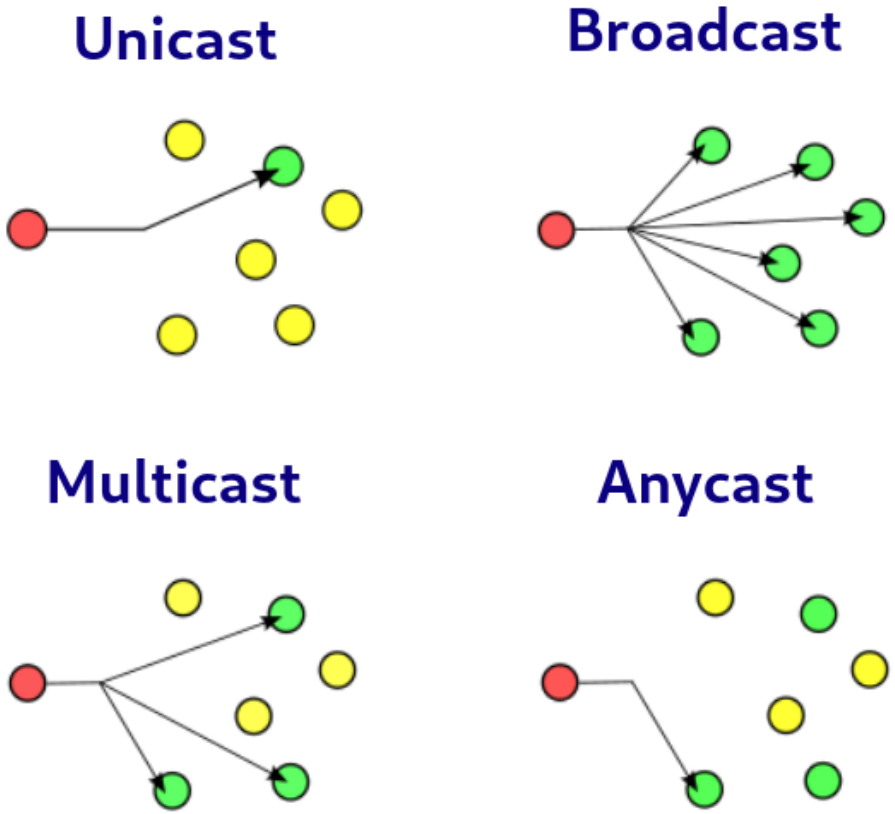

Multicast vs Unicast

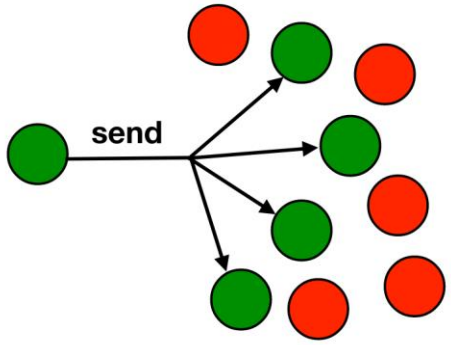

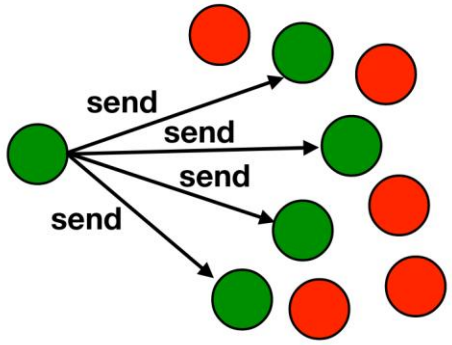

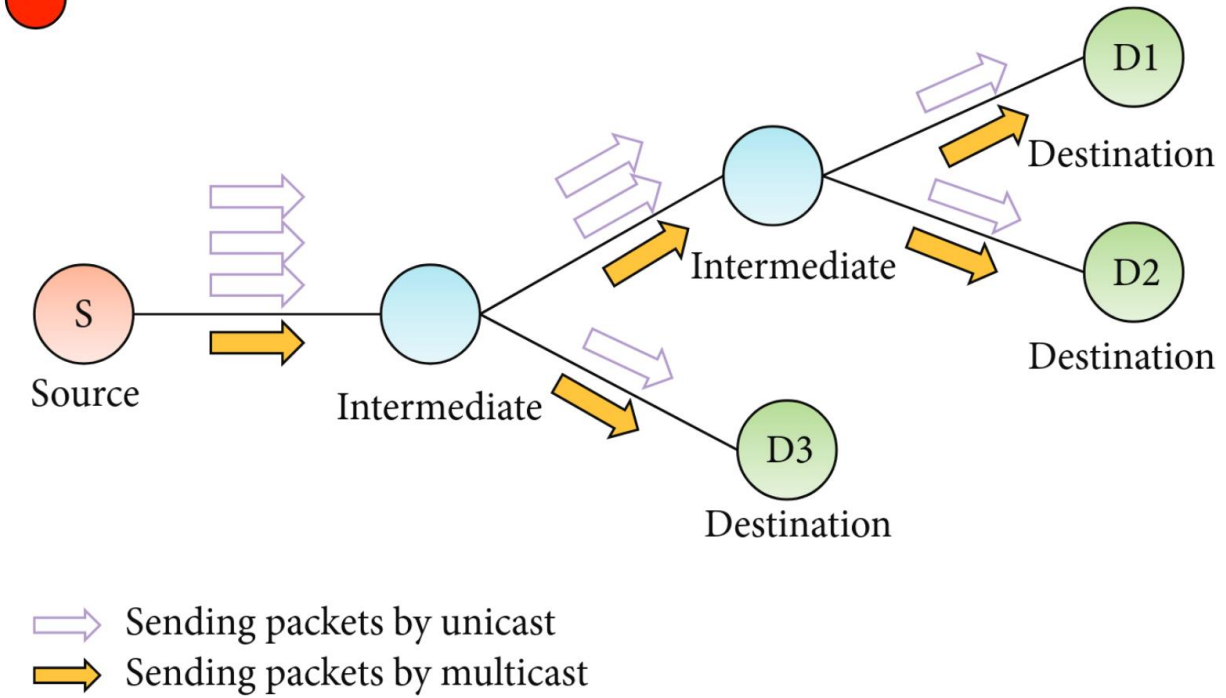

Реализация рассылки

- На уровне сети
  - канальный уровень (Ethernet)
  - сетевой уровень (IP)
- На уровне приложения

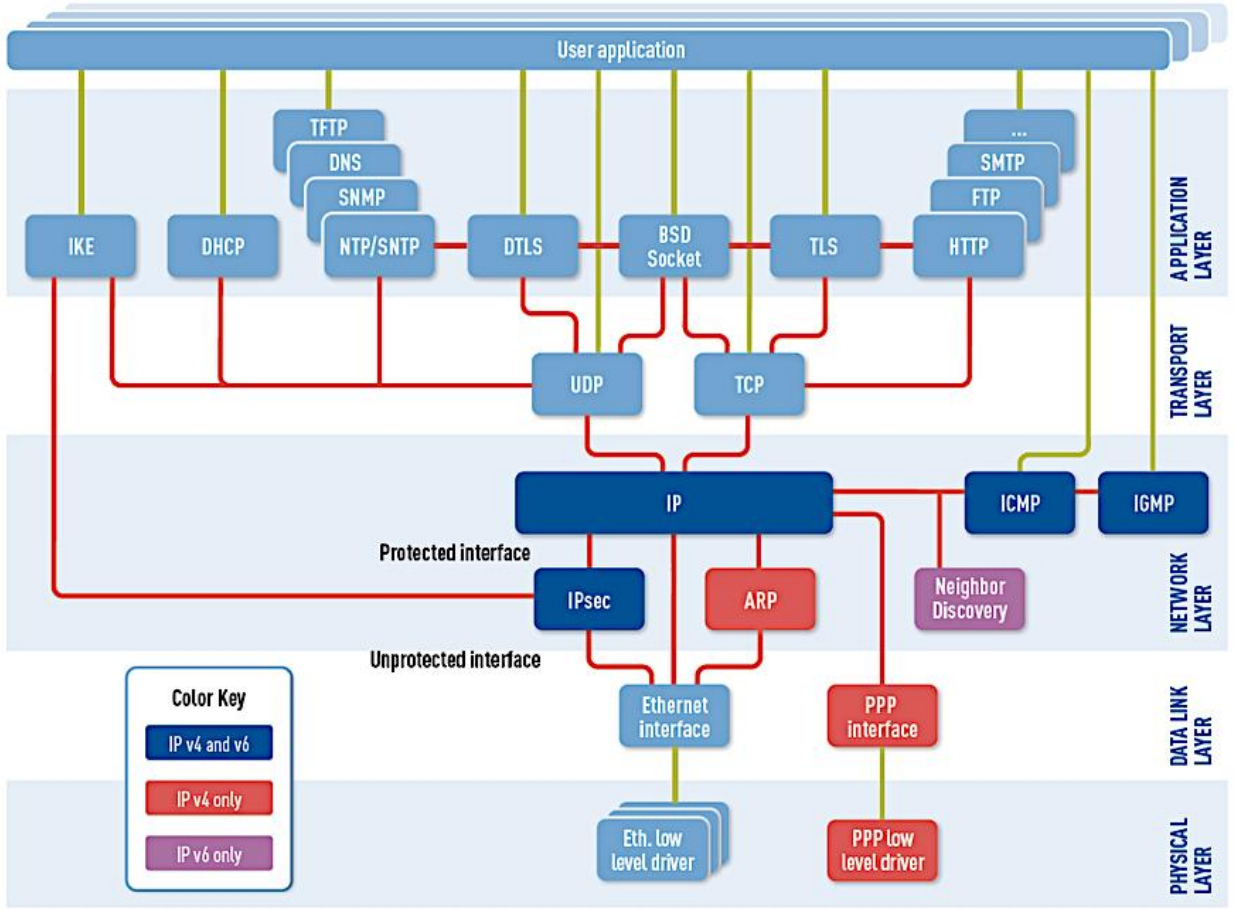

Ethernet

- Выделенный диапазон MAC-адресов
- Рассылка по всем устройствам в сети

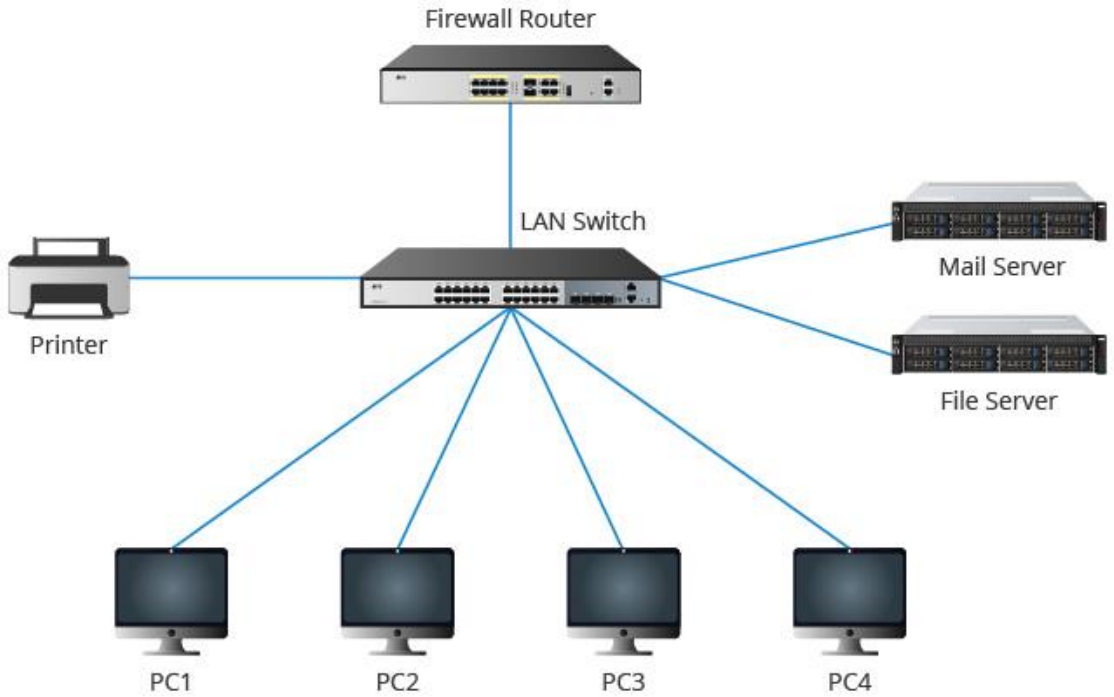

IP Multicast

- Позволяет отправить один пакет сразу всем участникам multicast-группы
  - Группа идентифицируется с помощью уникального IP-адреса
  - Машины в сети могут динамически вступать и выходить из групп
  - Для отправки данных не требуется быть участником группы
- Доступ на уровне приложений обычно реализован через протокол UDP

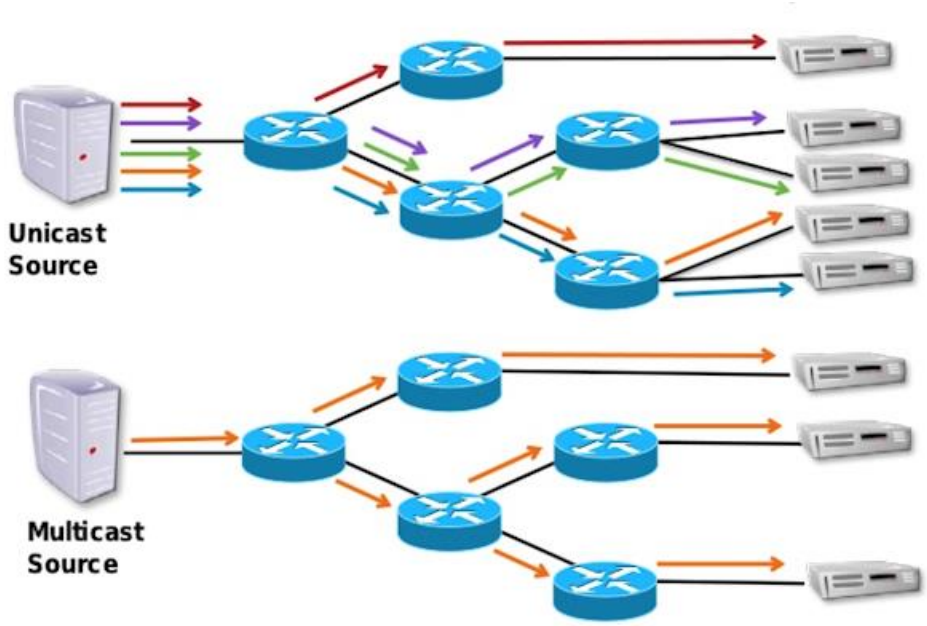

Гарантии IP Multicast

- Мультикаст на базе UDP
  - контроль целостности
  - доставка не гарантируется
  - сохранение порядка сообщений не гарантируется
- Протокол Pragmatic General Multicast (PGM)
  - IETF experimental protocol
  - надежная доставка и сохранение порядка сообщений
  - использует отрицательные подтверждения (NAKs)

IP Multicast в глобальной сети

- Требуется поддержка со стороны маршрутизаторов
- Распространение данных контролируется с помощью TTL (time to live)
- Основные протоколы: IGMP, PIM, MSDP

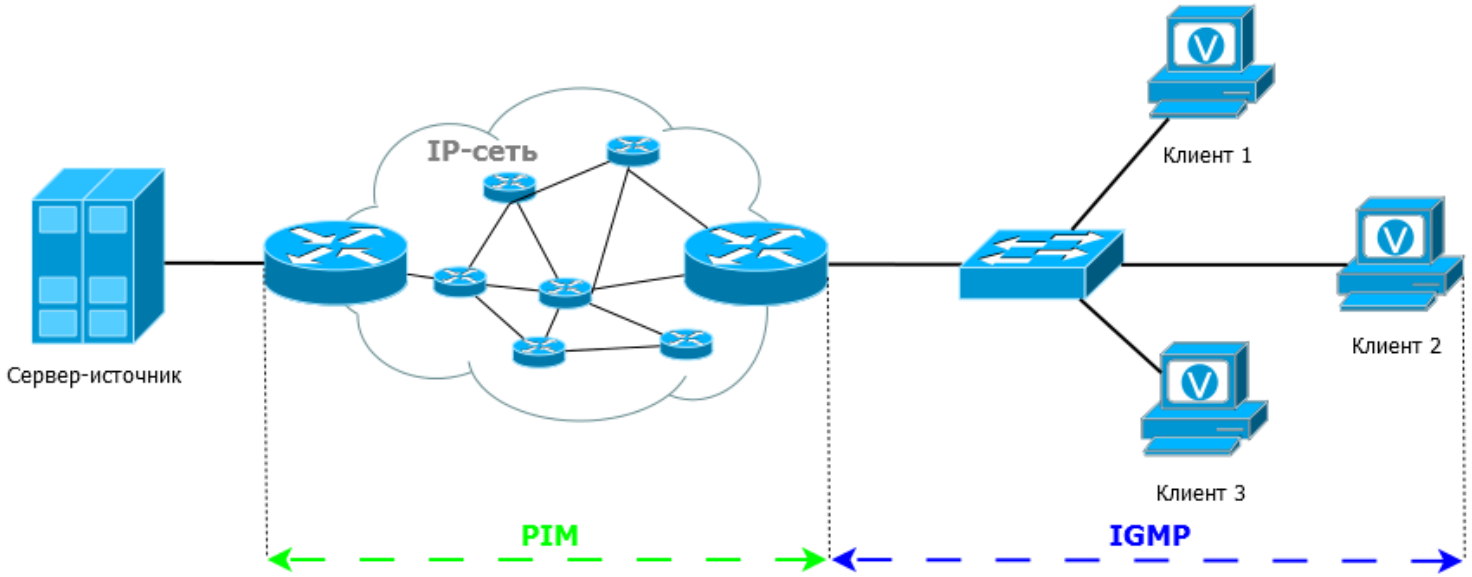

Рассылка на уровне приложения

- Мотивация
  - Отсутствует поддержка со стороны сети
  - Недостаточно предоставляемых возможностей и гарантий
- Важные элементы дизайна
  - Адресация участников группы
  - Надежность и семантика доставки
  - Порядок доставки
  - Семантика ответа
  - Состав и открытость группы

Интерфейс

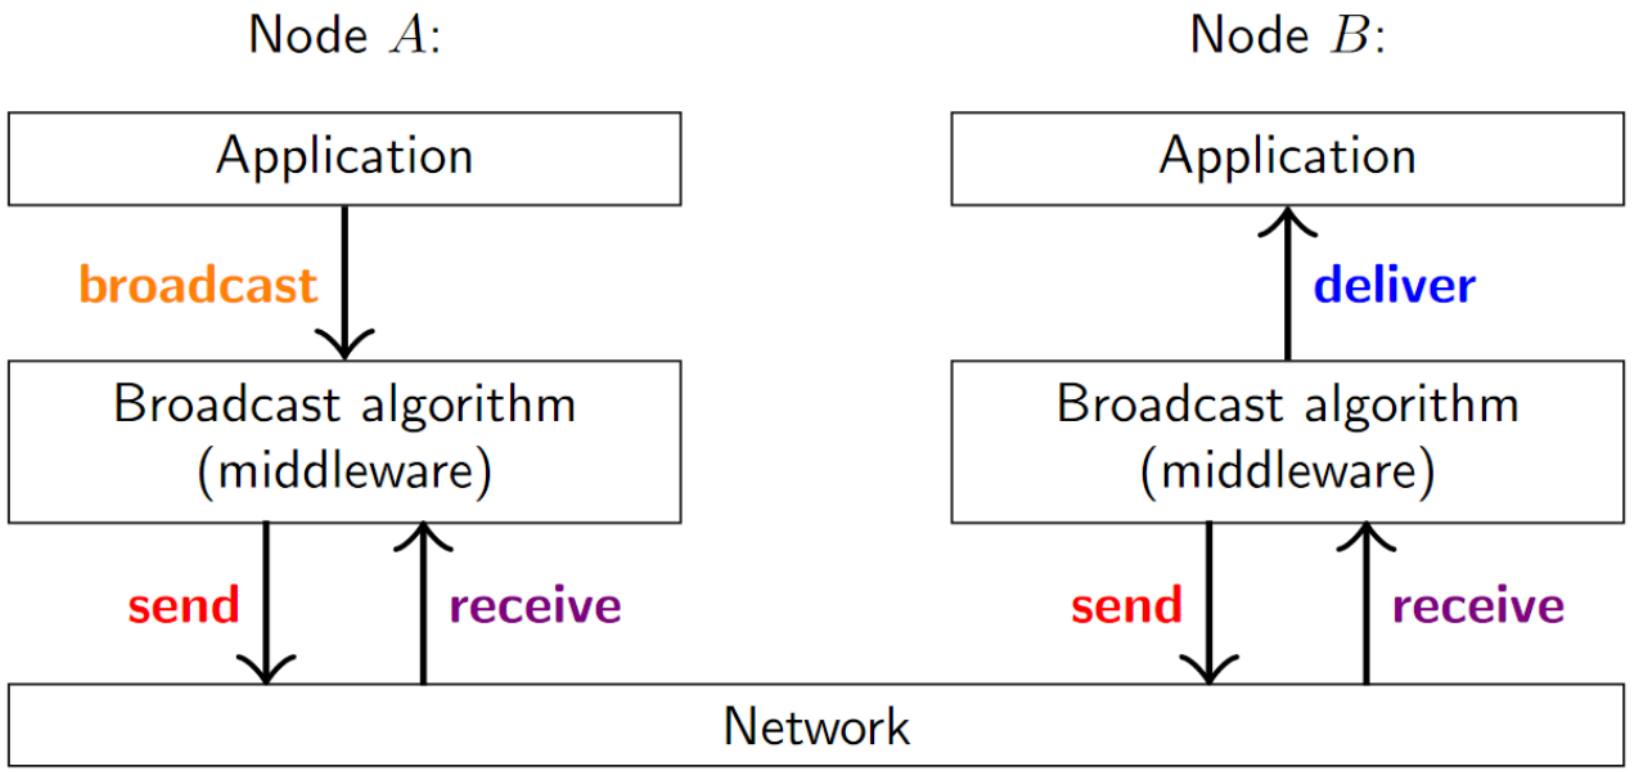
Node A:
Node B:
Application
Application
broadcast
deliver
Broadcast algorithm
(middleware)
Broadcast algorithm
(middleware)
send
receive
send
receive
Network

Предположения

Рассмотрим реализацию рассылки в следующих предположениях:

- группа ***закрытая***, состав участников группы зафиксирован
- все процессы в группе знают адреса друг друга
- каналы между процессами являются ***надежными*** (см. далее)
- процессы могут отказывать только путем ***полной остановки***
  - отказавший процесс не возвращается в систему
  - процесс, который не отказал в ходе рассылки, будем называть ***корректным***

Надежный канал (point-to-point)

- **Validity:** каждое сообщение будет доставлено
  - если корректный процесс ***p*** отправил сообщение ***m*** корректному процессу ***q***, то ***q*** в конце концов доставит ***m***
- **No Duplication:** отсутствуют повторы сообщений
  - никакое сообщение не доставляется процессом более одного раза
- **No Creation:** сообщения доставляются без искажений
  - если некоторый процесс ***q*** доставил сообщение ***m*** от процесса ***p***, то ***m*** было ранее отправлено от ***p*** к ***q***
- **Integrity:** No Duplication + No Creation

Best-Effort Broadcast (BEB): Свойства

- **Validity:** если корректный процесс разослал сообщение ***m***, то каждый корректный процесс в конце концов доставит ***m***
- **No Duplication:** корректный процесс ***p*** доставляет сообщение ***m*** не более одного раза
- **No Creation:** если корректный процесс ***p*** доставил сообщение ***m*** с отправителем ***s***, то ***m*** было ранее разослано ***s***

Какие истории удовлетворяют BEB?

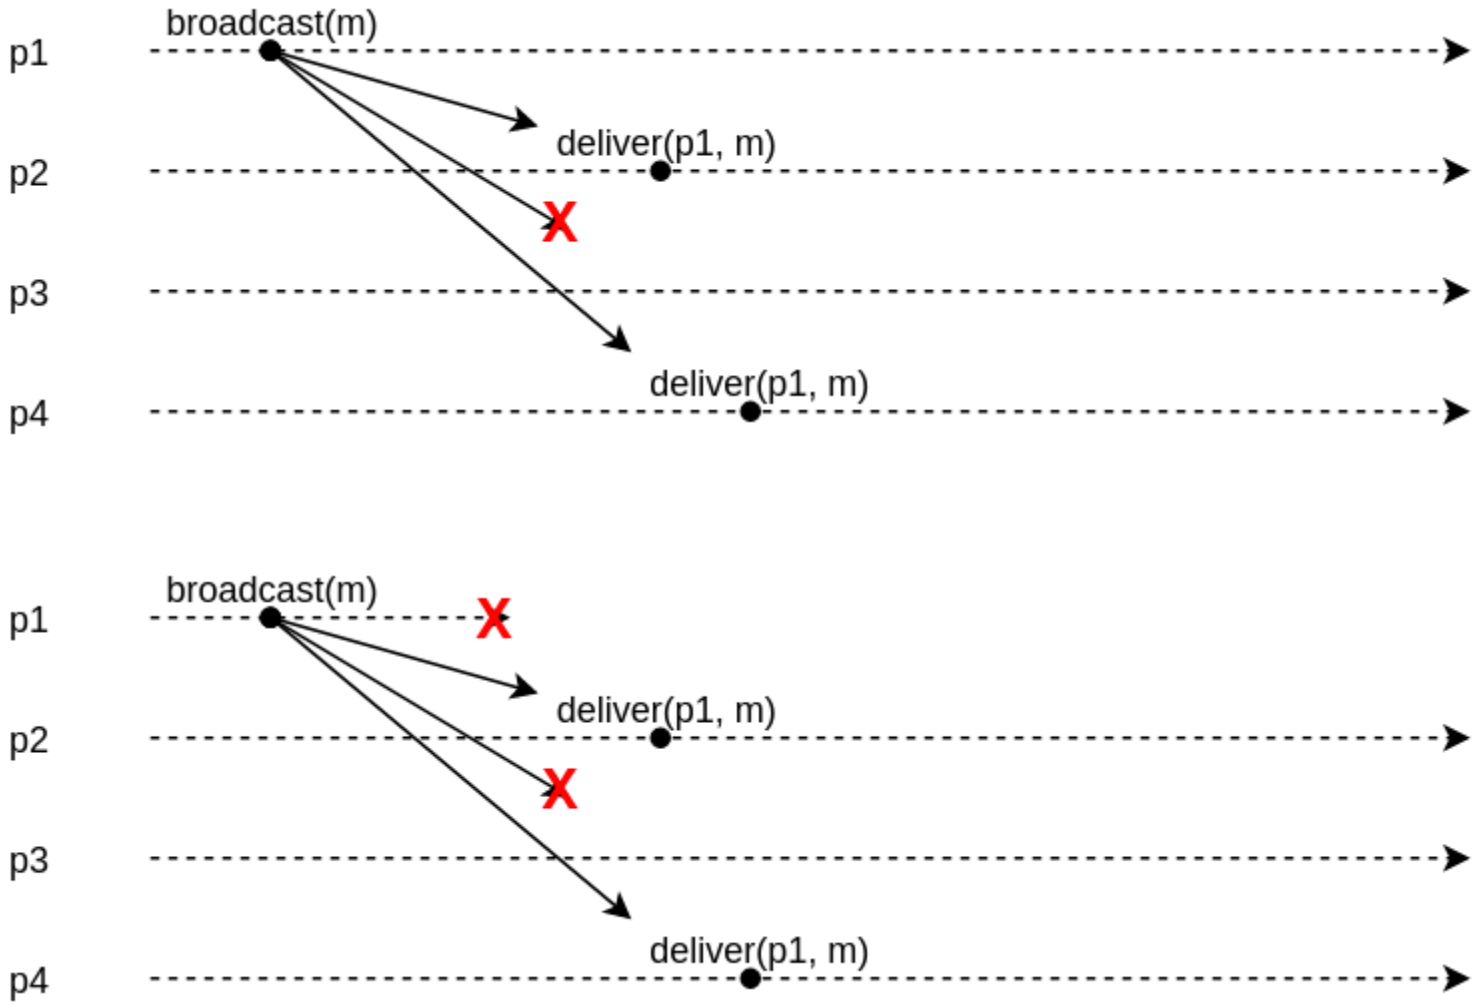

Best-Effort Broadcast: Реализация

```
On broadcast(msg):
    for proc in group:
        send(proc, msg)

On receive(msg) at proc:
    deliver(msg)
```

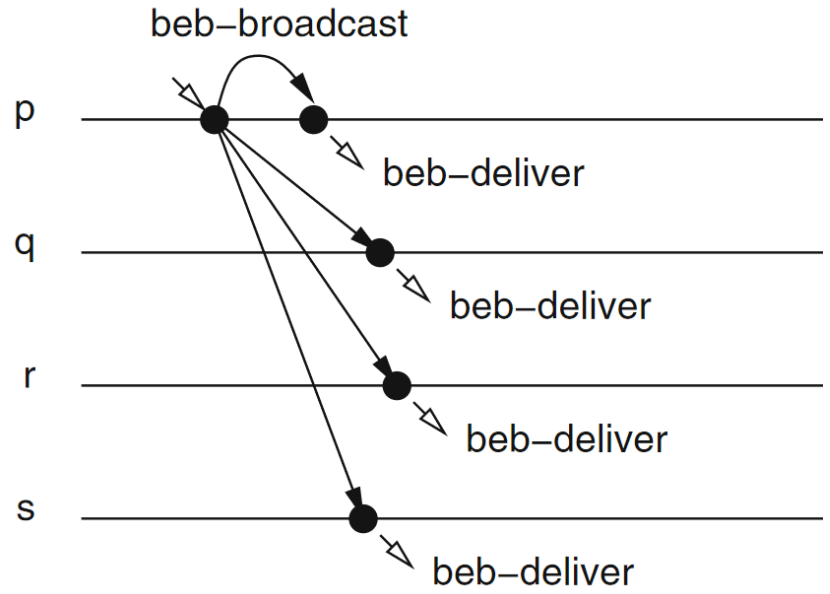

- Использует надежный point-to-point канал в виде операции **send()**
- Выполнение свойств следует из свойств надежного канала
- Подвержена *Ack-Implosion Problem*

Отказ отправителя

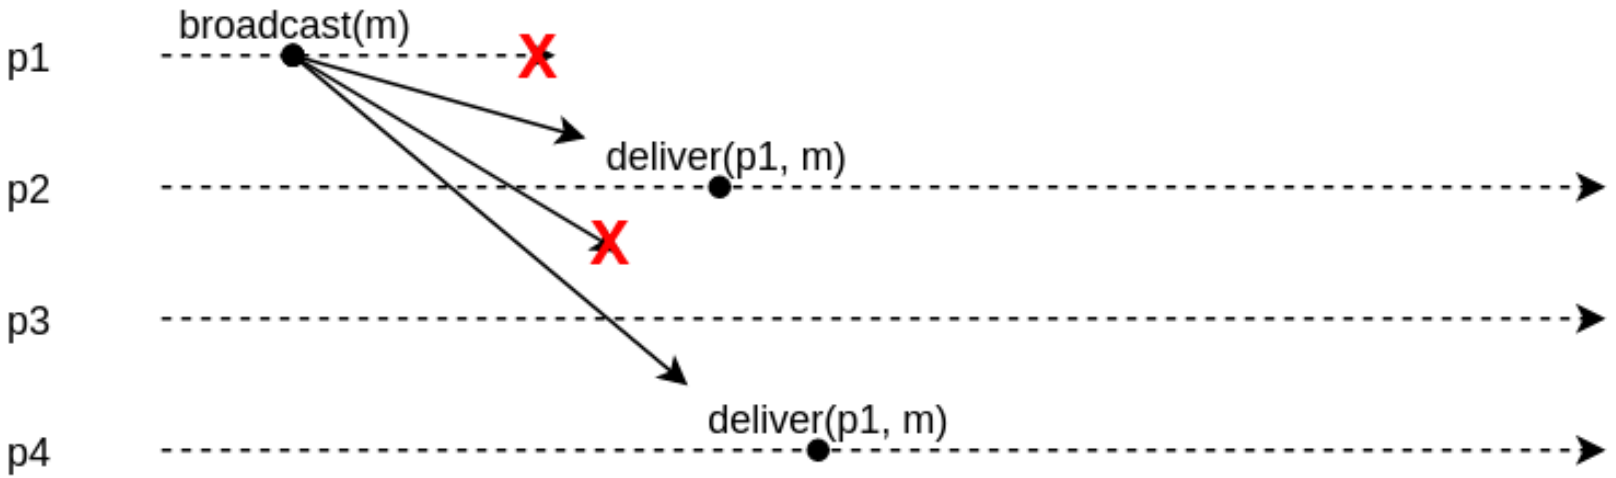

- BEB гарантирует доставку только если отправитель корректный
- При отказе отправителя часть процессов в группе может получить и доставить сообщение, а часть нет
- Отсутствует **согласие** между процессами относительно доставки сообщения

Reliable Broadcast (RB): Свойства

- **Validity:** если корректный процесс разослал сообщение ***m***, то ~~каждый корректный процесс~~ он в конце концов доставит ***m***
- **No Duplication:** корректный процесс ***p*** доставляет сообщение ***m*** не более одного раза
- **No Creation:** если корректный процесс ***p*** доставил сообщение ***m*** с отправителем ***s***, то ***m*** было ранее разослано ***s***
- **Agreement:** если некоторый корректный процесс доставил сообщение ***m***, то все остальные корректные процессы в группе в конце концов доставят ***m***

Какие истории удовлетворяют RB?

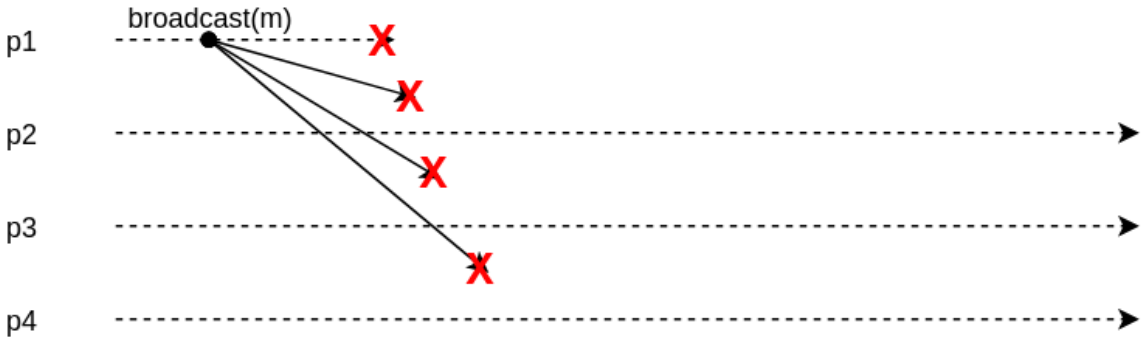

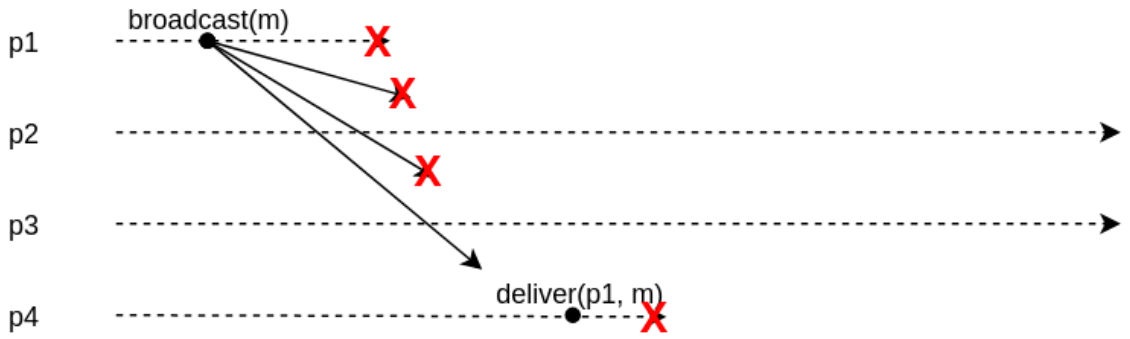

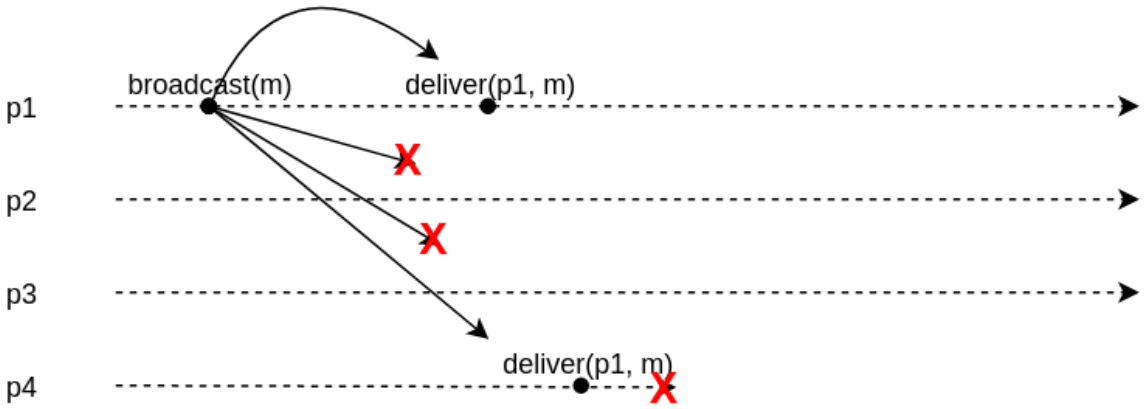

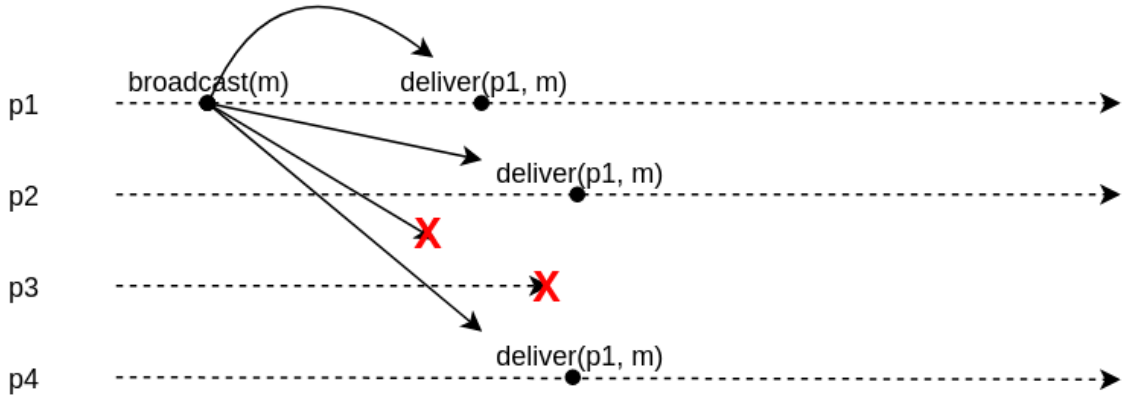

Eager Reliable Broadcast

```
On init:
    delivered = {}

On broadcast(msg):
    BEB.broadcast(msg)

On BEB.deliver(msg) :
    if msg not in delivered:
        delivered.add(msg)
        if self != msg.sender:
            BEB.broadcast(msg)
        deliver(msg)
```

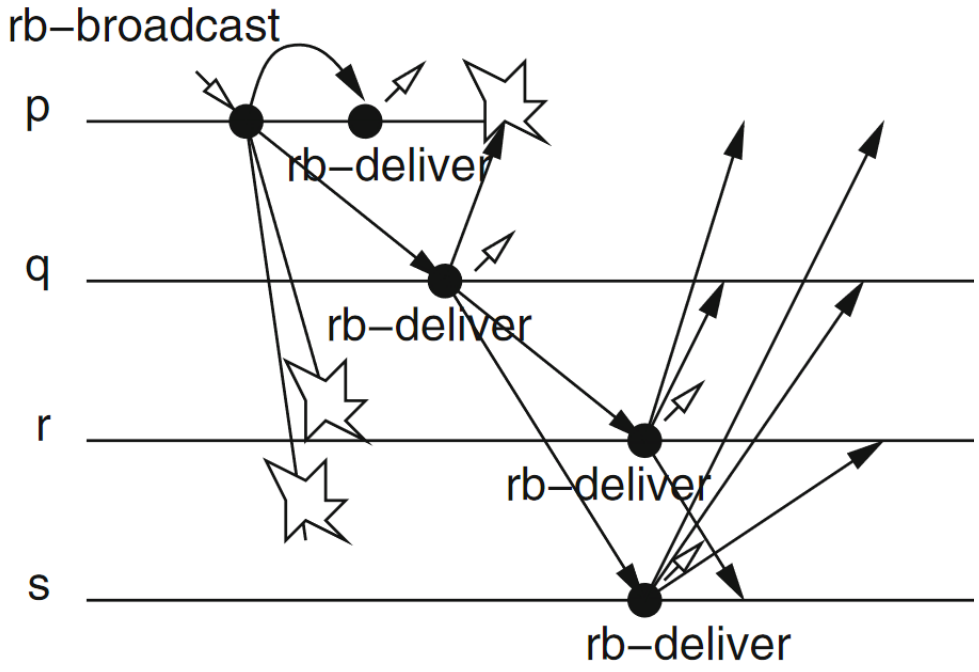

- Упражнение: показать, что выполняются свойства Reliable Broadcast
- Низкая эффективность – $O(N^2)$ сообщений!

Другие реализации Reliable Broadcast

- Gossip (см. далее в лекции)
- Lazy вариант с детектором отказов (см. далее в курсе)
- IP multicast + подтверждения

Reliable Broadcast поверх IP Multicast (1)

- Используем IP multicast и подтверждения
  - подтверждения отправляются вместе с рассылаемыми сообщениями (piggyback)
  - отдельное сообщение в случае обнаружения пропуска сообщения (negative ack)
- Каждый процесс p хранит локально
  - S_p^g – sequence number сообщений процесса в группе g, в начале 0
  - R_q^g – номер последнего доставленного им сообщения от q в g
- Отправка сообщения
  - к сообщению добавляются значение S_p^g и подтверждения $\langle q, R_q^g \rangle$
  - сообщение с добавкой рассылается через IP multicast
  - значение S_p^g увеличивается на 1

Reliable Broadcast поверх IP Multicast (2)

- Получение сообщения с номером S от p
  - если $S = R_p^g + 1$, то сообщение доставляется и R_p^g увеличивается на 1
  - если $S \leq R_p^g$, то сообщение было получено ранее и отбрасывается
  - если $S > R_p^g + 1$, то сообщение помещается в *hold-back queue*
  - если $S > R_p^g + 1$ или $R > R_q^g$ для подтверждения $\langle q, R \rangle$ из сообщения, то какие-то сообщения еще не получены и возможно потеряны при рассылке
  - процесс запрашивает недостающие сообщения от их отправителей или других процессов, которые получали эти сообщения, путем отправки NAK

Reliable Broadcast поверх IP Multicast (3)

- Особенности
  - требуется постоянная (бесконечная) рассылка сообщений
  - необходимо (вечное) хранение доставленных сообщений на всех процессах
  - попутно получили сохранение порядка сообщений от каждого процесса

Uniform Agreement

- Расширение свойства Agreement с корректных до всех процессов:

  Если некоторый ~~корректный~~ процесс доставил сообщение ***m***, то все корректные процессы в группе в конце концов доставят ***m***

- Даже если процесс отказал после доставки сообщения, корректные процессы также должны доставить это сообщение

- Когда может потребоваться такое свойство?
- Удовлетворяют ли ему наши реализации Reliable Broadcast?
- Как обеспечить это свойство? (см. домашнее задание)

Порядок доставки сообщений

- Реализации надежной рассылки могут не давать гарантий относительно порядка доставки сообщений
- Возможные варианты гарантий:
  - Произвольный порядок (нет гарантий)
  - Порядок отправки (FIFO Order)
  - Причинный порядок (Causal Oder)
  - Полный порядок (Total Order)

FIFO Order

Если корректный процесс сначала разослал ***m*** а потом ***m'***, то любой корректный процесс, который доставил ***m'***, доставит ***m*** до ***m'***

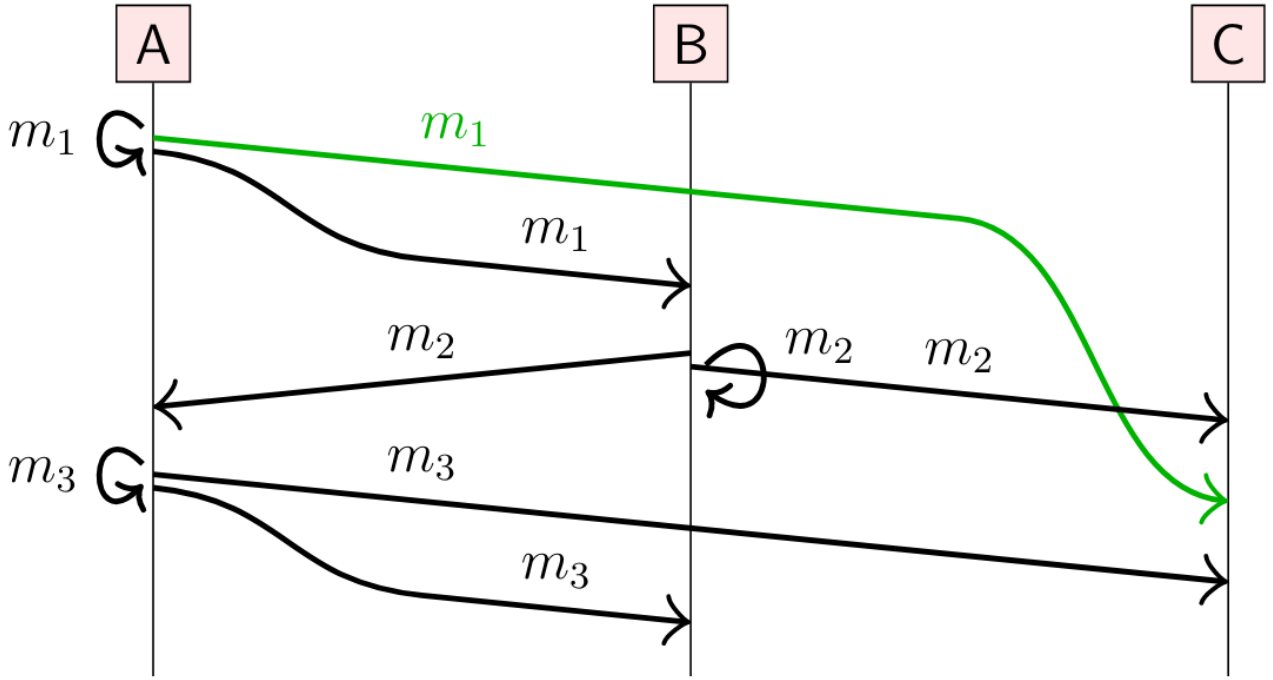

Causal Order

Сообщения доставляются с сохранением причинно-следственных зависимостей:

- Сообщение ***m*** могло повлиять на сообщение ***m'*** от процесса ***p***, если ***m*** было отправлено или доставлено процессом ***p*** до отправки ***m'***
- Если сообщение ***m*** могло повлиять на сообщение ***m'***, то любой корректный процесс, который доставил ***m'***, доставит ***m*** до ***m'***

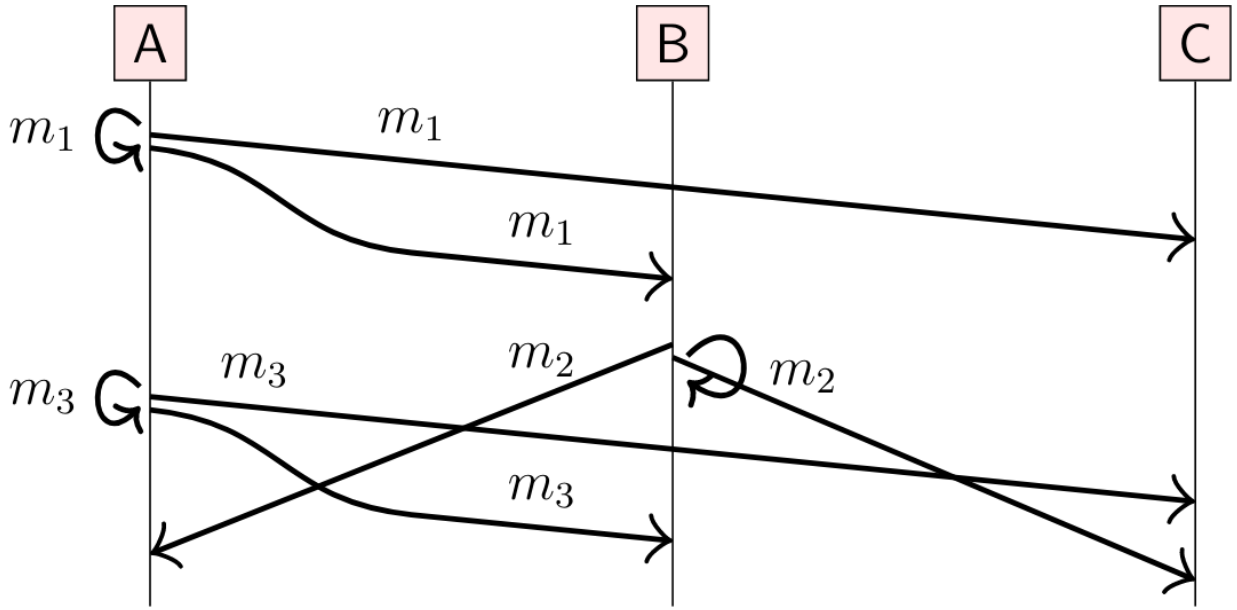

Total Order

Если некоторый корректный процесс доставил ***m*** до ***m'***, то любой другой корректный процесс, который доставил ***m'***, доставит ***m*** до ***m'***

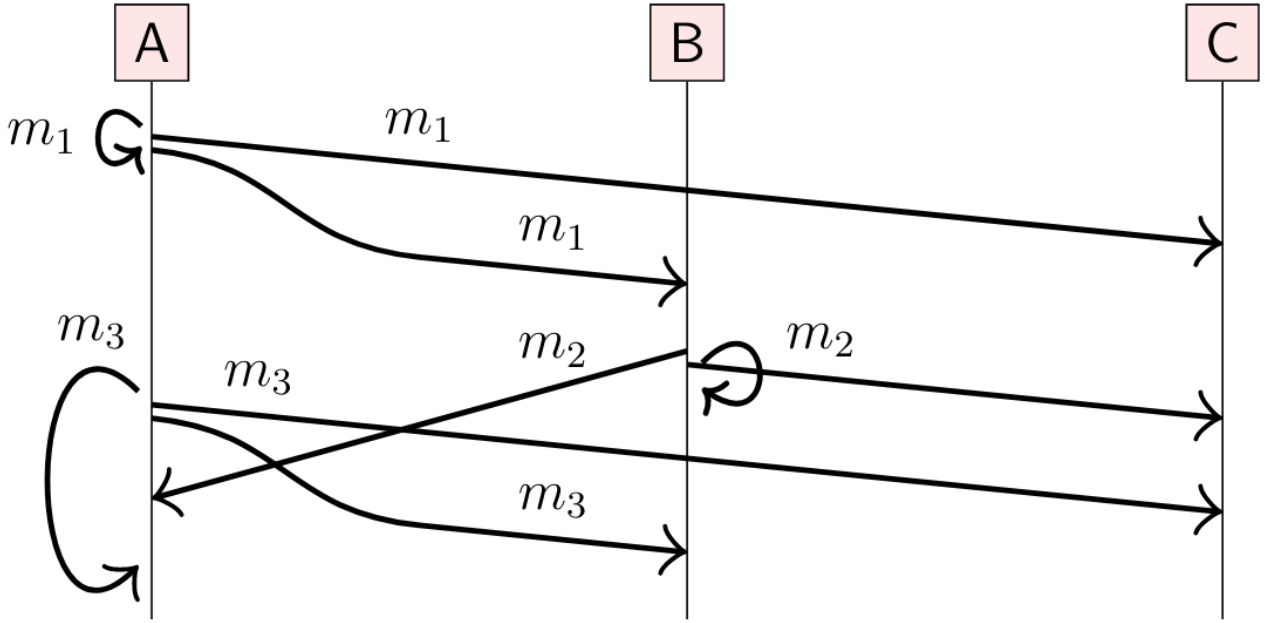

Сравнение гарантий

- FIFO Order
  - частичный порядок
- Causal Oder
  - частичный порядок
  - включает в себя FIFO
- Total Order
  - полный порядок
  - не гарантирует FIFO или Causal порядки
  - возможные комбинации: FIFO-Total, Causal-Total
  - FIFO-Total включает в себя Causal

Реализация FIFO Broadcast

- Основана на использовании sequence numbers
- Каждый процесс p хранит локально
  - S_p^g - сколько сообщений p отправил в группу g
  - R_q^g - номер последнего сообщения от q в g, которое доставил p
- При отправке процесс добавляет к сообщению S_p^g и затем увеличивает S_p^g на 1
- При получении сообщения с номером S от процесса q
  - если $S = R_q^g + 1$, то сообщение доставляется
  - если $S > R_q^g + 1$, то сообщение добавляется в hold-back queue
- Для рассылки достаточно использовать Best-effort Broadcast
  - если использовать Reliable Broadcast, то получим Reliable FIFO Broadcast

Реализация Causal Broadcast

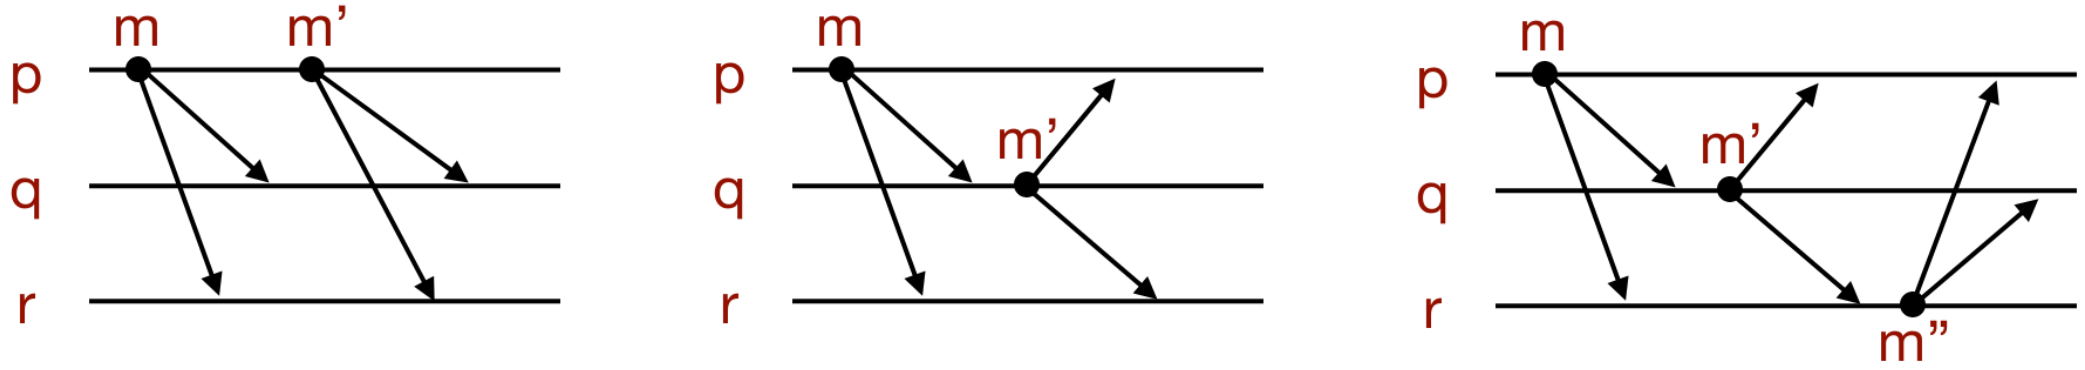

- Каждый процесс p поддерживает локально вектор размера N
  - j-я компонента вектора равна числу сообщений, которые p доставил от j
- Векторы рассылаются вместе с сообщениями и используются для упорядочивания сообщений
- Разновидность ***векторных часов***, рассматриваемых далее в курсе
- Для рассылки можно использовать Best-effort или Reliable Broadcast

Реализация Causal Broadcast

```
On init:
    V[j] = 0 (j = 1..N)

On broadcast(msg):
    V[self] += 1
    BEB.broadcast(<msg, V>)

On BEB.deliver(<msg, V*>) from j:
    place <msg, V*> in hold-back queue
    wait until V*[j] = V[j] + 1 and V*[k] <= V[k] (k != j)
    remove <msg, V*> from hold-back queue
    deliver(msg)
    V[j] += 1
```

Реализация Total Order Broadcast

- Основная идея: назначить каждому сообщению уникальный номер
  - sequence numbers на уровне всей группы
  - каждый процесс может локально упорядочить сообщения
- Возможные подходы
  - централизованный – выделенный процесс-лидер (sequencer)
  - распределенный – процессы согласуют номера друг с другом, логические часы
  - см. литературу к лекции

Разновидности рассылки

- Best-effort Broadcast
- Reliable Broadcast
- (Reliable) FIFO Broadcast
- (Reliable) Causal Broadcast
- (Reliable) Total Order Broadcast

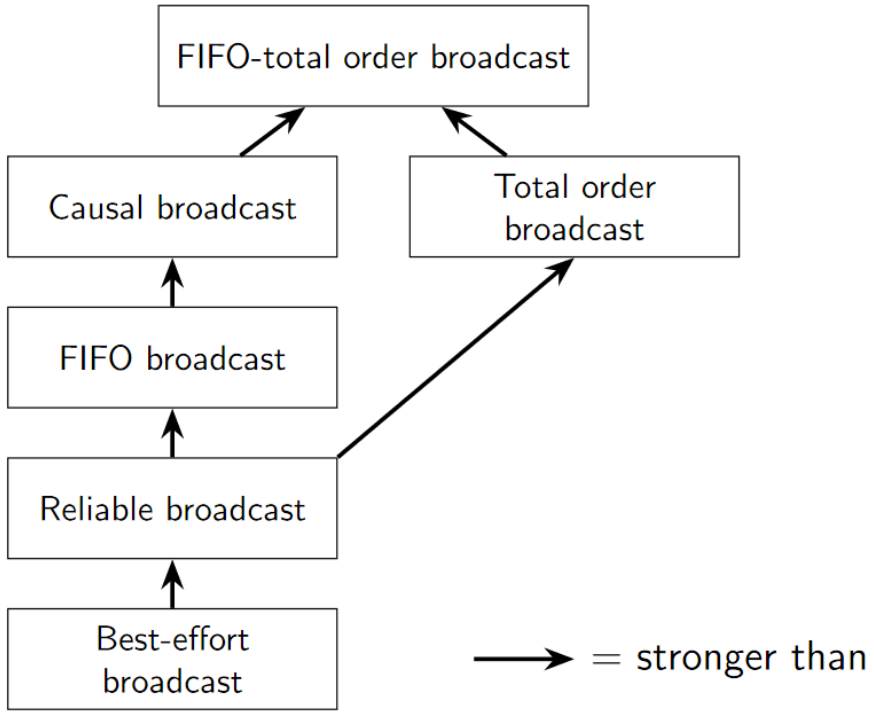

Reliable Total Order Broadcast (a.k.a. Atomic Broadcast) эквивалентен задаче консенсуса, рассматриваемой позже в курсе

Масштабируемость?

- Ранее акцент был на гарантиях надежности и порядка
- Мы использовали упрощающие предположения
  - отказы только типа полной остановки
  - все процессы знают друг друга
  - состав групп зафиксирован
- Как обеспечить масштабируемость, если
  - участников много
  - они могут находиться в разных частях Интернета и не знать друг о друге
  - классические подходы не работают или создают большую нагрузку на сеть

Масштабируемые подходы

- Топологии на базе оверлейных сетей
  - рассылки по дереву или mesh-сети
- Распространение информации с вероятностными гарантиями
  - probabilistic broadcast, epidemic protocols, gossiping…

Ослабленные гарантии надежности и порядка взамен на лучшую масштабируемость и устойчивость

Оверлейная сеть (overlay network)

- "Виртуальная" сеть поверх физической сети
- Реализует набор сервисов
  - специфичных для приложения
  - более эффективных, чем доступные в обычной сети
  - недоступных в обычной сети
- Основные элементы
  - Топология
  - Адресация узлов
  - Протоколы
  - Алгоритмы маршрутизации

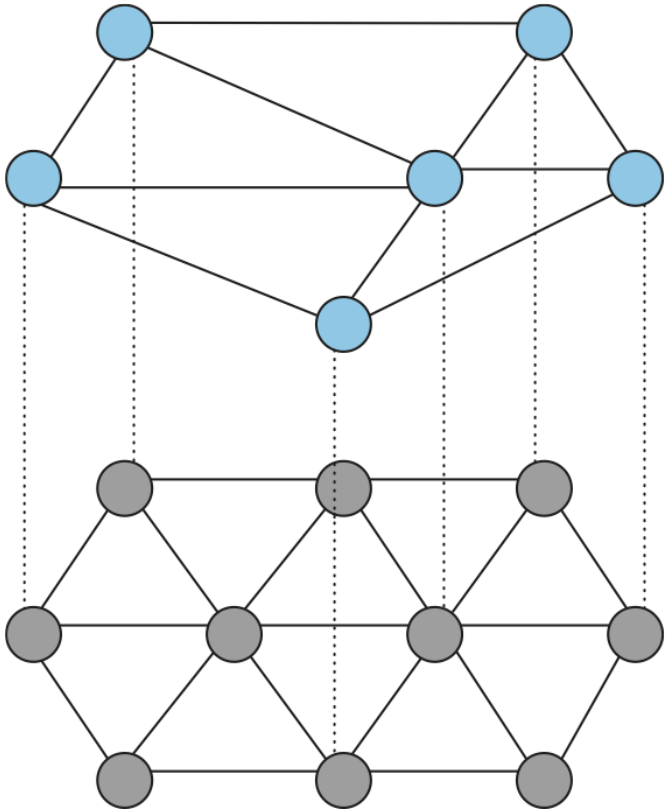

Применение оверлейных сетей

- Мультикаст
- Доставка контента, VoIP, потоковое видео
- Улучшенная маршрутизация в Интернете
- Именование и поиск (peer-to-peer сети, DHT)
- Беспроводные и самоорганизующиеся сети
- Обеспечение безопасности (VPN)

Возможные топологии

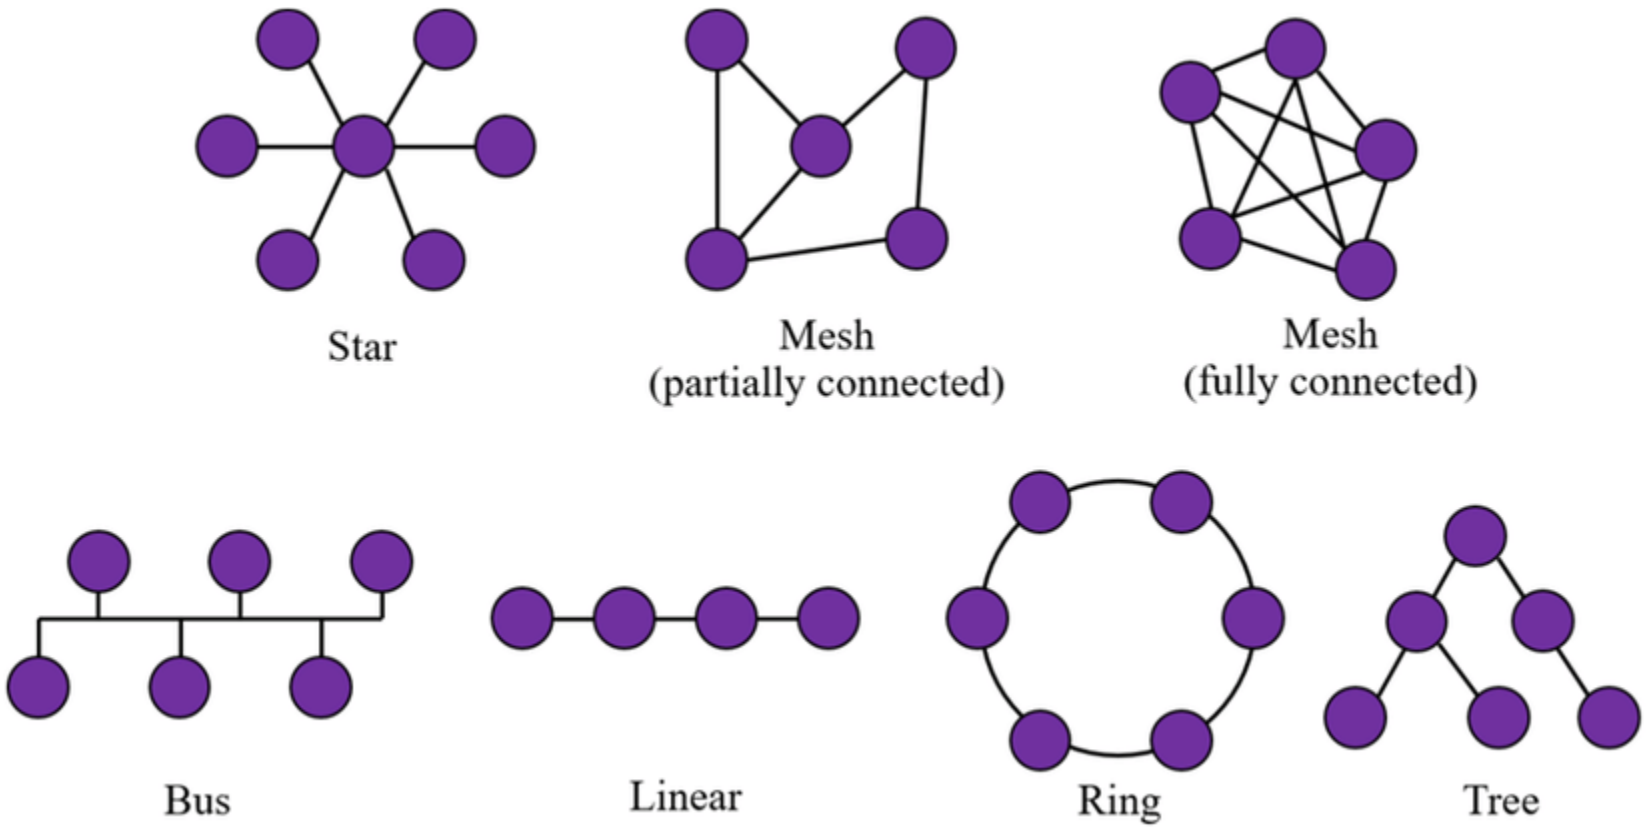

Дерево

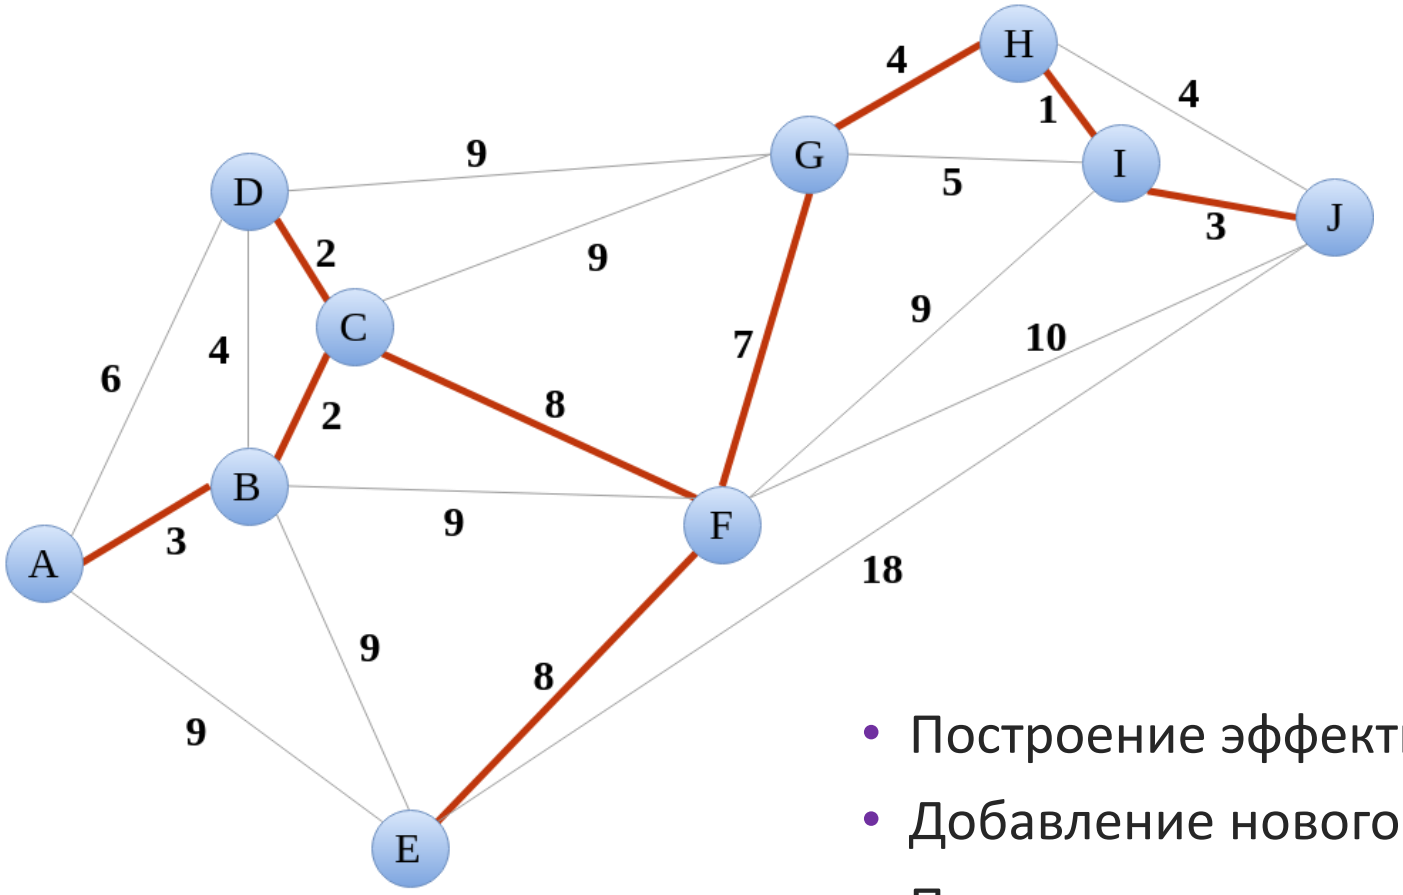

- Построение эффективного остовного дерева
- Добавление нового узла
- Починка дерева в случае отказа
- Примеры: Plumtree (НИС), switch-trees (литература)

Mesh-сеть

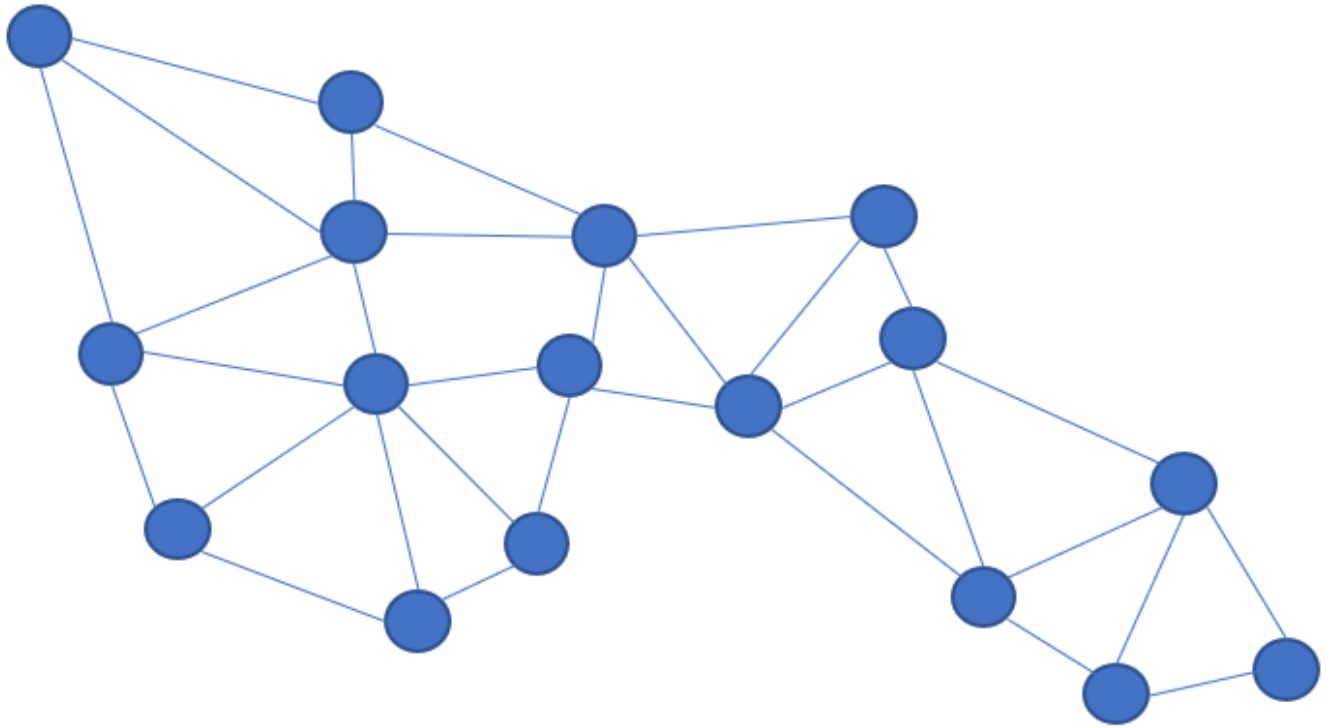

- Высокая устойчивость к отказам за счёт избыточных связей
- Хорошо приспособлена к динамическому составу участников
- Сложнее организовать эффективную рассылку
- Может требоваться буферизация полученных данных (pull)

Gossip

- Подход к распространению информации на основе локальных связей
  - Аналогии с распространением слухов или болезней (epidemic protocols)
- Возможные состояния узла:
  - infected, susceptible, removed
- В каждом раунде узел взаимодействует с одним или несколькими (т.н. *fanout*) соседями
- Для распространения данных на все узлы требуется $O(logN)$ раундов

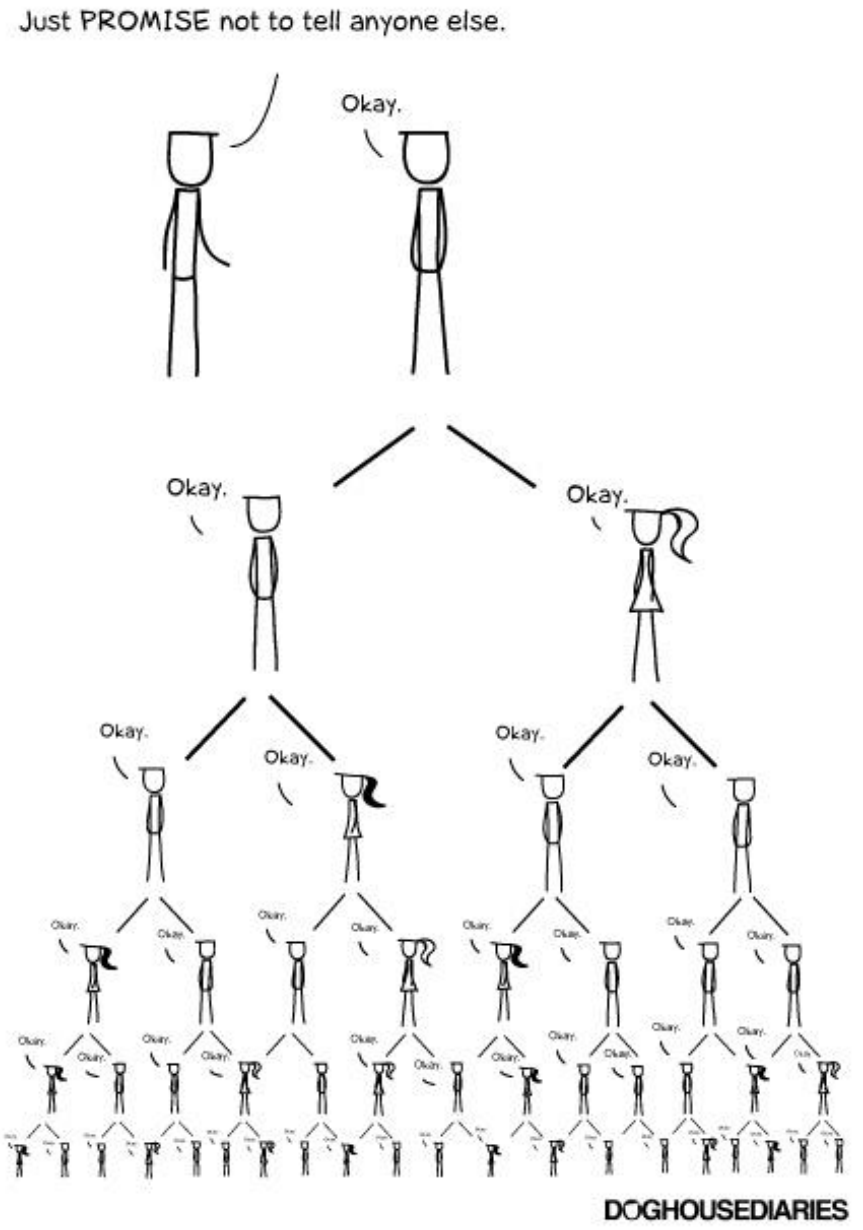

Симулятор

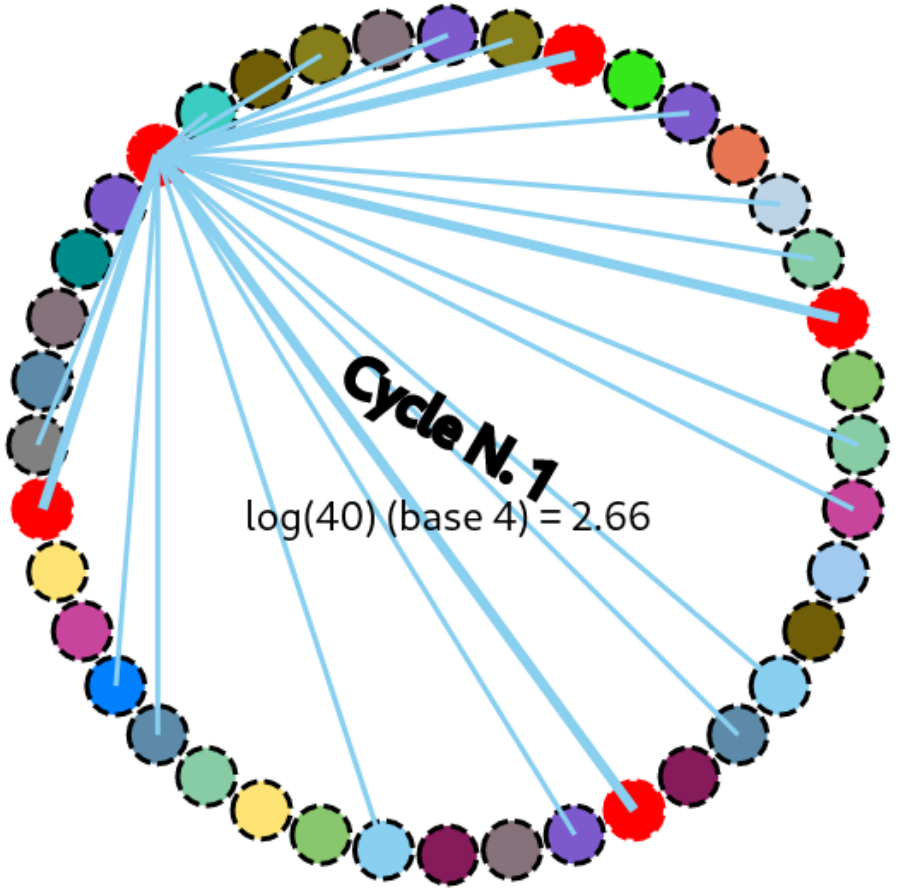

https://flopezluis.github.io/gossip-simulator/

Анти-энтропия

Узел p выбирает случайным образом другой узел q

- **Push:** p отправляет q известную ему информацию (обновления)
- **Pull:** p запрашивает у q известную тому информацию
- **Push-Pull:** p и q обмениваются известной им информацией

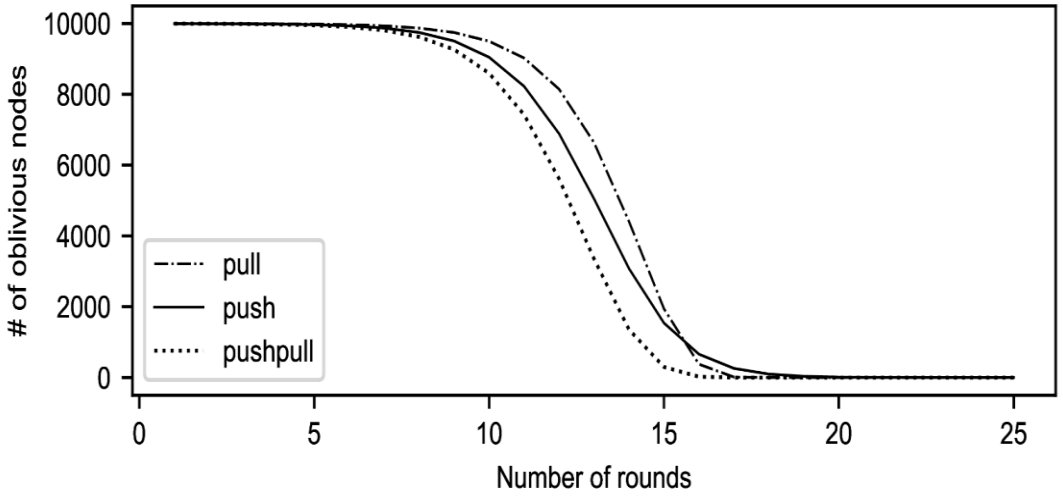

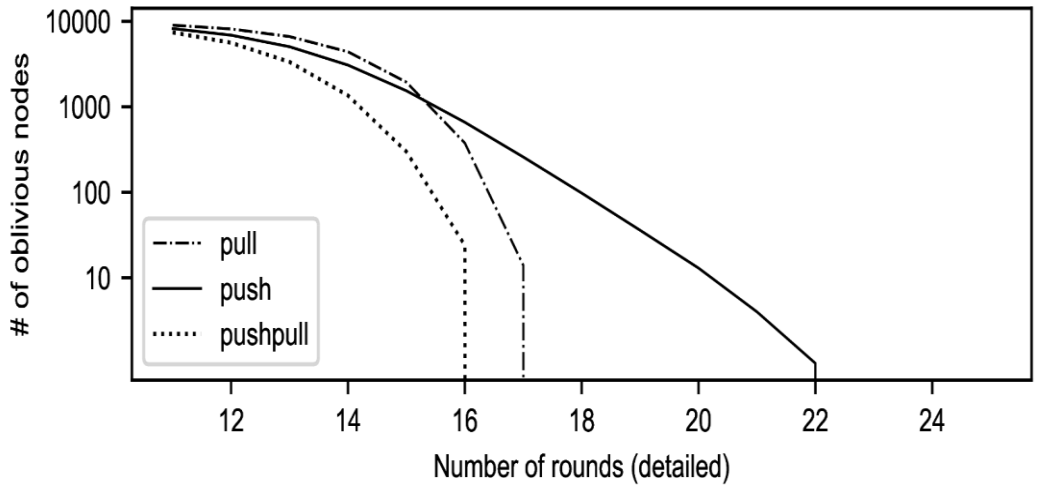

Rumor spreading

- Если сосед уже имеет информацию, то узел перестает распространять ее с вероятностью p_{stop}
- Не гарантирует распространение информации до всех узлов

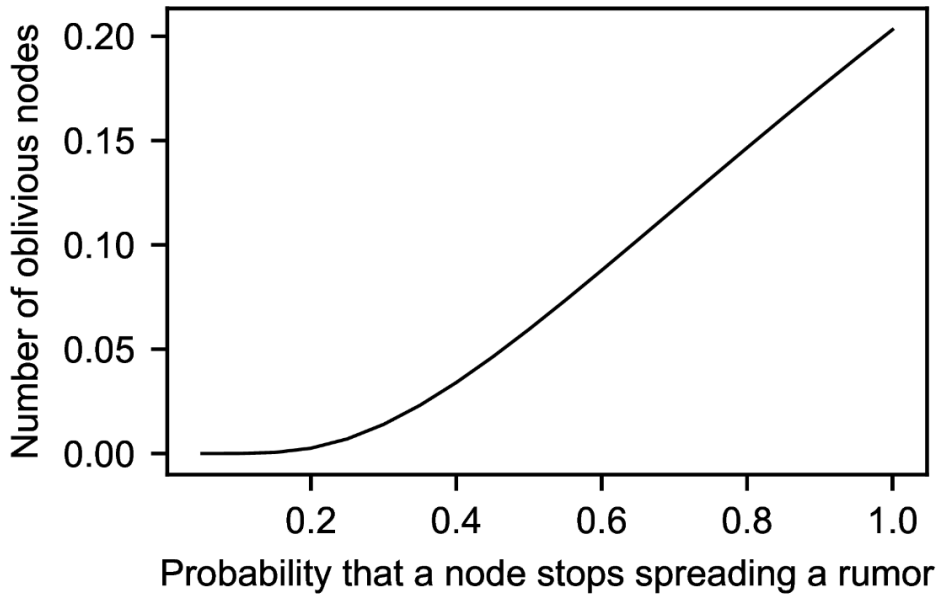

Материалы

- Distributed Systems: Concepts and Design (разделы 4.4, 4.5, 6.2, 15.4)
- Сети для самых маленьких (часть 9)
- Computer Networks: A Systems Approach (разделы 4.3, 9.4)
- Distributed Systems Course (разделы 4.2-4.3)
- Distributed Systems: Principles and Paradigms (раздел 4.4)
- Epidemic Broadcast Trees